数据结构与程序设计（信息类）

Data Structure and Programming

北航软件学院 谭火彬

数据结构与程序设计（信息类）

Data Structure and Programming

第 6 章

查找(Searching)

目录

CONTENTS

数据结构与程序设计（信息类）

Data Structure and Programming

第 6 章

查找(Searching)

目录

CONTENTS

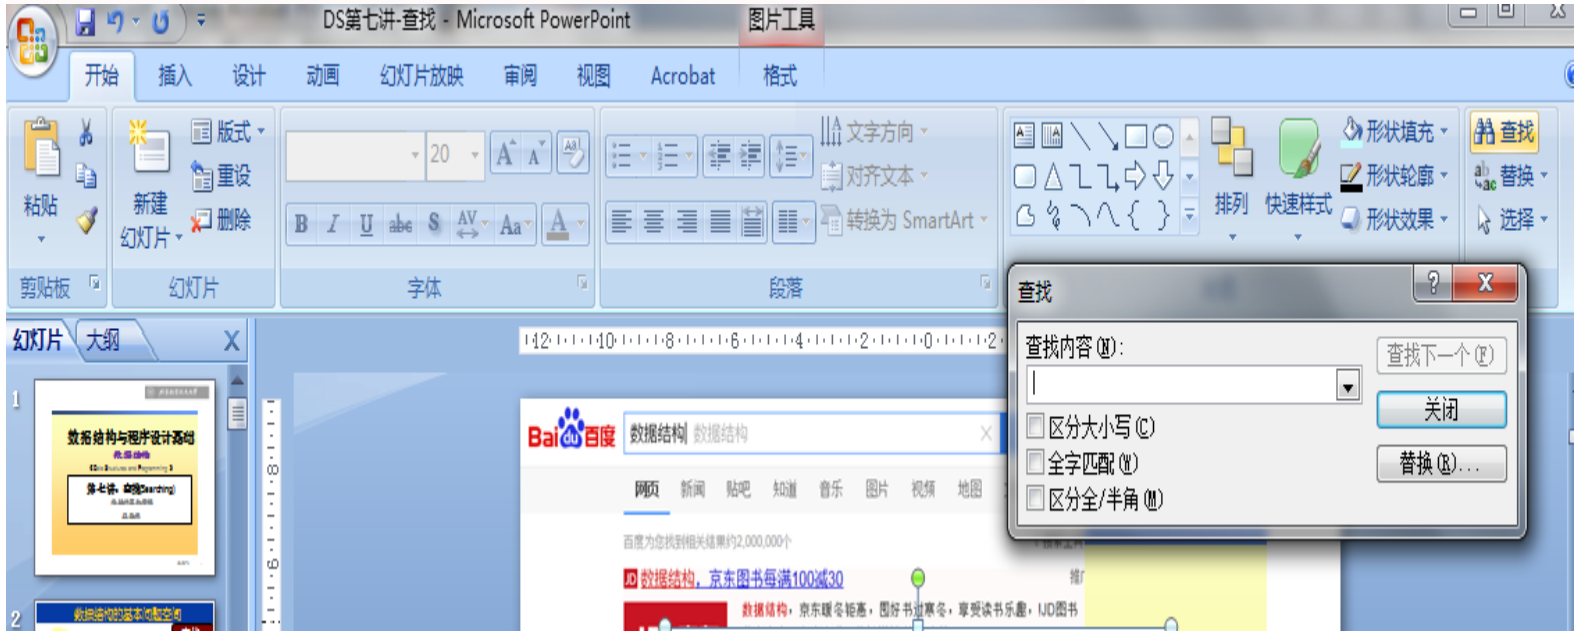

互联网时代，几乎我们每个人都会要用到搜索

6.1 查找的基本概念

- 查找（搜索，Searching）就是根据给定的值在数据集中确定一个其关键字等于给定值的数据元素（或记录）

学 号	姓 名	性别	年龄	其 他
99001	张 三	女	20	… …
99002	李 四	男	18	… …
99003	王 五	男	17	… …
…	…	…	…	… …
…	…	…	…	… …
…	…	…	…	… …
99030	刘 末	女	19	… …

名词术语

- 记录(record)：反映一个客体数据信息的集合
- 属性(attribute, 字段、数据项)：
  描述一个客体某一方面特征的数据信息
- 查找表(table)：
  具有相同属性定义的记录的集合
- 关键字(key)：
  区分不同记录的属性或属性组
  - ◆主关键字：可唯一标识一个记录
  - ◆次关键字

学 号	姓 名	性别	年龄	其 他
99001	张 三	女	20	… …
99002	李 四	男	18	… …
99003	王 五	男	17	… …
…	…	…	…	… …
…	…	…	…	… …
…	…	…	…	… …
99030	刘 末	女	19	… …

查找表的逻辑结构和物理结构

- 逻辑结构：一种线性结构
  - 记录呈现在用户眼前的排列的先后次序关系
- 物理结构
  - 查找表（文件）在存储介质上的组织方式
    - 顺序组织存储：顺序查找、折半查找
    - 链式组织存储：顺序查找
    - 索引组织存储：索引查找
    - 散列组织存储：散列查找

查找表的基本操作

查找

在查找表中确定某个特定记录存在与否的过程

结论：查找成功,给出被查到记录的位置；
查找失败,给出相应的信息。

(1) 查找表的第i个记录；
(2) 查找当前位置的下一个记录；
(3) 按关键字值查找记录。

插入
删除
修改

以查找操作为基础

排序

使记录按关键字值有序排列的过程

静态查找表与动态查找表

- 静态查找表
  - 如果只在查找表中确定某个特定记录是否存在或检索某个特定记录的属性，此类查找表为静态查找表(Static Search Table)
- 动态查找表
  - 如果在查找表中需要插入不存在的数据元素（记录）或需要删除检索到的数据元素（记录），此类查找表为动态查找表(Dynamic Search Table)

数据结构与程序设计（信息类）

Data Structure and Programming

第 6 章

查找(Searching)

目录

CONTENTS

6.2 顺序表的查找

- 顺序表
  - 记录在存储时，遵循其逻辑结构排列的先后次序存储和组织的查找表称为顺序表
- 逻辑划分
  - 记录的排列按关键字值有序的顺序表称为有序顺序表，否则，称为一般顺序表
- 物理划分
  - 在存储介质上采用连续组织方式的顺序表称为连续顺序表
  - 采用链接组织方式的顺序表称为链接顺序表
  - 若有序顺序表在存储介质上采用连续组织方式，称之为有序连续顺序表

连续顺序表的顺序查找

- 基本思想
  - 从表的第一个记录开始，将用户给出的关键字值与当前被查找记录的关键字值进行比较，若匹配，则查找成功，给出被查到的记录在表中的位置，查找结束
  - 若所有n 个记录的关键字值都已比较，不存在与用户要查的关键字值匹配的记录，则查找失败，给出信息0（物理位置下标为-1）

$(key_1, key_2, key_3, \ldots, key_n)$

k

被查找记录的关键字值

关键字集合

算法实现

```
int search(keytype key[], int n, keytype k)
{
    int i;
    for (i = 0; i < n; i++)
        if (key[i] == k)
            return i;
    return -1;
}
```

例

key[0..9]　38　75　19　57　100　48　50　7　62　11

若查找 k=48　经过6次比较，查找成功，返回 i=5

若查找 k=35　查找失败，返回信息 -1

查找性能评价

平均查找长度ASL (Average Search Length)

确定一个记录在查找表中的位置所需要进行的关键字值的比较次数的期望值(平均值)。

对于具有n个记录的查找表，有 $ASL=\sum_{i=1}^{n} p_i c_i$

其中，p_i为查找第i个记录的概率，c_i为查找第i个记录所进行过的关键字的比较次数

$$ASL=\sum_{i=1}^{n} p_i c_i = \frac{1}{n}\sum_{i=1}^{n} i = \frac{n+1}{2}$$

算法的时间复杂度为O(n)

顺序表的顺序查找法

- 优点
  - 查找原理和过程简单，易于理解
  - 对于被查找对象的排列次序没有限制
- 缺点
  - 查找效率比较低
- 思考：插入对象的位置对查询效率是否有影响？
  - 随机插入
  - 在头部插入
  - 在尾部插入
  - 按顺序插入

2. 有序连续顺序表的折半查找（Binary Search）

- 折半查找（二分查找，对半查找）
  - 将要查找的关键字值与当前查找范围内位置居中的记录的关键字的值进行比较
    - 若匹配，则查找成功，给出被查到记录在文件中的位置，查找结束
    - 若要查找的关键字值小于位置居中的记录的关键字值，则到当前查找范围的前半部分重复上述查找过程，否则，到当前查找范围的后半部分重复上述查找过程，直到查找成功或者失败
  - 若查找失败，则给出错误信息

算法的几个变量

n　有序连续顺序文件中记录的个数

low 当前查找范围内第一个记录在文件中的位置

初值 low=0

high 当前查找范围内最后那个记录在文件中的位置

初值 high=n-1

mid 当前查找范围内位置居中的那个记录在文件中的位置

$$mid = \left\lfloor \frac{low+high}{2} \right\rfloor$$

算法实现：非递归算法

```
int binsearch(keytype key[], int n, keytype k){
    int low = 0, high = n - 1, mid;
    while (low <= high)
    {
        mid = (low + high) / 2;
        if (k == key[mid])
            return mid; /*查找成功*/
        if (k > key[mid])
            low = mid + 1; /*准备查找后半部分 */
        else
            high = mid-1; /*准备查找前半部分 */
    }
    return -1; /*查找失败  */
}
```

算法实现：递归算法

```
int binsearch2(keytype key[], int low, int high, keytype k){
    int mid;
    if (low > high)
        return -1;
    else
    {
        mid = (low + high) / 2;
        if (k == key[mid])
            return mid;
        else if (k < key[mid])
            return binsearch2(key, low, mid-1, k);
        else
            return binsearch2(key, mid + 1, high, k);
    }
}
```

low=0; 在第1次调用的算法中
high=n-1;
pos=binsearch2(KEY, low, high, k);

查找效率如何

利用判定树分析算法性能

若把当前查找范围内居中的记录的位置作为根结点，前半部分与后半部分的记录的位置分别构成根结点的左子树与右子树,则由此得到一棵称为“判定树”的二叉树，利用它来描述折半查找的过程

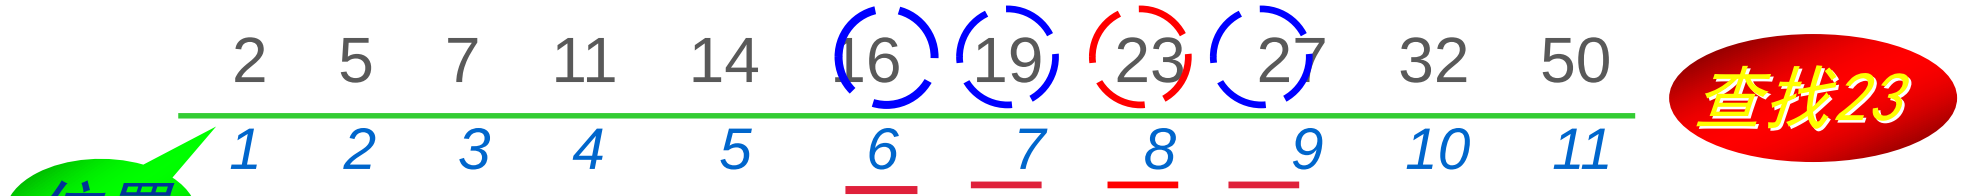

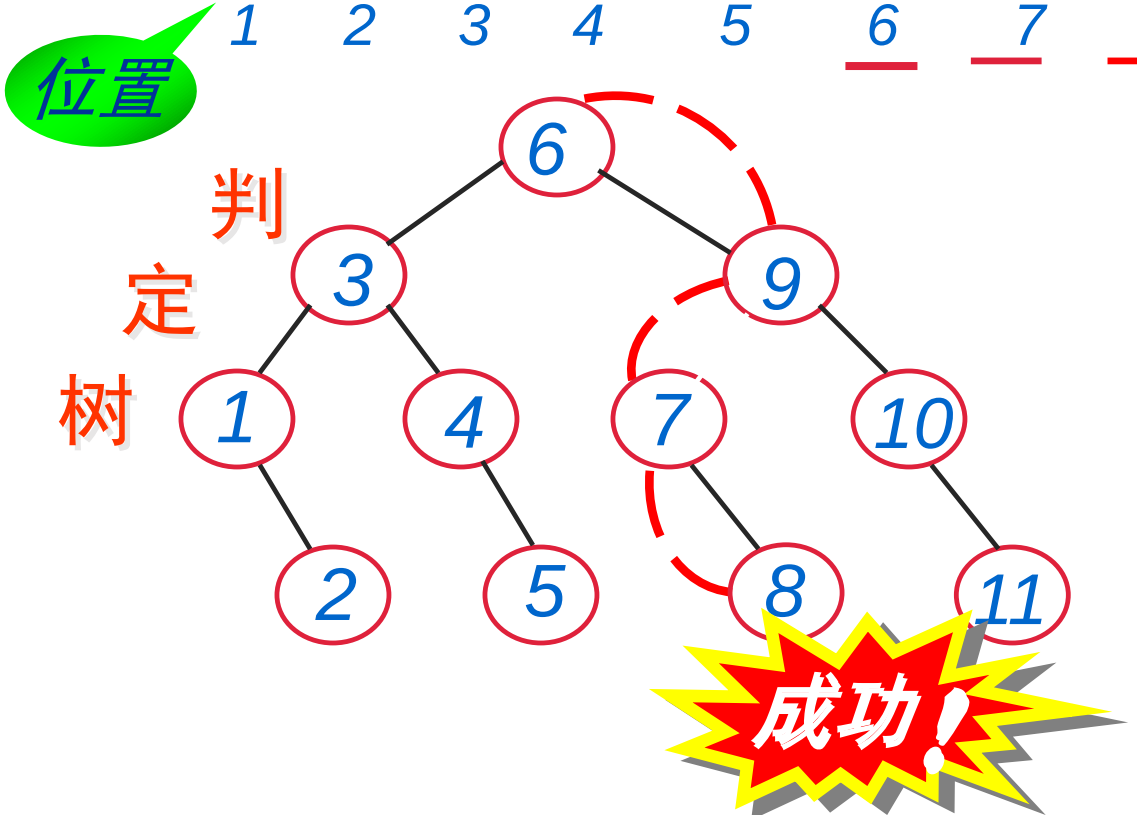

结论

成功的查找过程正好等于走了一条从根结点到被查找结点的路径，经历的比较次数恰好是被查找结点在二叉树中所处的层次数！

平均查找长度和时间复杂度

对于具有n个记录的有序连续顺序文件，若查找概率相等，则有

$$ASL=\sum_{i=1}^{n} p_i c_i = \frac{1}{n}\sum_{j=1}^{h} j\times 2^{j-1} = \frac{n+1}{n}\log_2(n+1) - 1$$

第j层结点数的最大值

第j层每个结点的比较次数

当n足够大时，有 $ASL\approx \log_2(n+1) - 1$

算法的时间复杂度: $O(\log_2 n)$

有序连续顺序表的折半查找

- 优点
  - 查找原理和过程简单，易于理解
  - 查找的时间效率较高
- 缺点
  - 要求查找表中的记录按照关键字值有序排列
  - 对于查找表，只适用于有序连续顺序表

为了保持数据集为有序顺序数据集，在数据集中插入和删除记录时需要移动大量的其它记录

折半查找方法适用于一经建立就很少改动、而又经常需要查找的查找表

思考

在线性表中采用折半查找方法查找数据元素，该线性表应该满足什么条件？

数据元素按值有序排列

必须采用顺序存储结构

基于折半查找的元素定位

- 对于动态表，通常元素没有查找到时要进行插入操作，基于折半查找算法，如何获取元素的插入位置？

```
int insertElem(ElemType list[], ElemType item){
    int i = 0, j;

    if (N == MAXSIZE) return -1;
    //折半查找寻找item的合适位置
    i = searchElem(list, item);

    for (j = N - 1; j >= i; j--)
        list[j + 1] = list[j];

    list[i] = item; //将item插入表中
    N++;
    return 1;
}
```

```
//折半查找算法，返回插入位置
int searchElem(ElemType list[], ElemType item){
    int low = 0, high = n - 1, mid;
    while (low <= high)    {
        mid = (high + low) / 2;
        if(( item < list[mid])
            high = mid - 1;
        else if ( item > list[mid])
            low = mid + 1;
        else
        return (mid);
    }
    return low;
}
```

更多的查找方法

延伸阅读*：

折半查找算法效率非常高（时间复杂度仅为$O(\log_2 n)$），针对一些特定的有序集，有没有更快的查找算法呢？

请同学自学有关插值查找(Interpolation Search)及斐波那契查找（Fibonacci Search）算法原理及C实现。

插值查找(Interpolation Search)*

对于有序顺序表，折半查找时：

mid = low + (high-low)/2

对于有序顺序表，插值查找时：

mid=low + (high-low)*(k-a[low])/(a[high]-a[low])

使用标准库中的查找函数

- 类似于qsort函数，标准库中提供了一个查找函数，实现按照关键字的查找（stdlib.h）

```
void* bsearch( const void *key, const void *ptr,
               size_t count, size_t size,
               int (*comp)(const void*, const void*) );
```

  - key　指向要查找的元素的指针
  - ptr　指向要检验的数组的指针
  - count 数组的元素数目
  - size　数组每个元素的字节数
  - comp 比较函数。若首个参数小于第二个，则返回负整数值，若首个参数大于第二个，则返回正整数值，若两参数相等，则返回零。 将 key 传给首个参数，数组中的元素传给第二个

3. 链接顺序表的查找

链结点

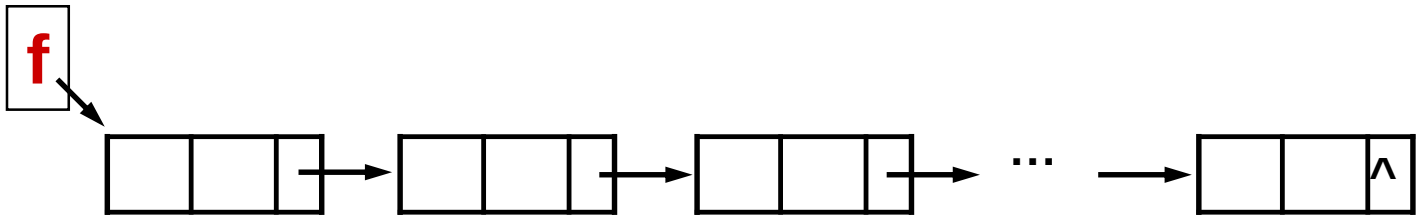

链接顺序表（链表）适合于动态查找表，但查找效率低

算法

```
struct node{
    keytype key;
    rectype rec;
    struct node *link;
};
```

```
struct node *search(struct node *p, keytype k)
{
    for (; p != NULL; p = p->link)
        if (p->key == k)
            return p; /* 查找成功 */

    return NULL; /* 查找失败 */
}
```

数据结构与程序设计（信息类）

Data Structure and Programming

第 6 章

查找(Searching)

目录

CONTENTS

6.3 索引

如何在大规模数据集中快速查找?

如何根据不同属性查找?

如何利用不同存储介质的性能特性实现快速查找?

不同的存储设备访问速度不同

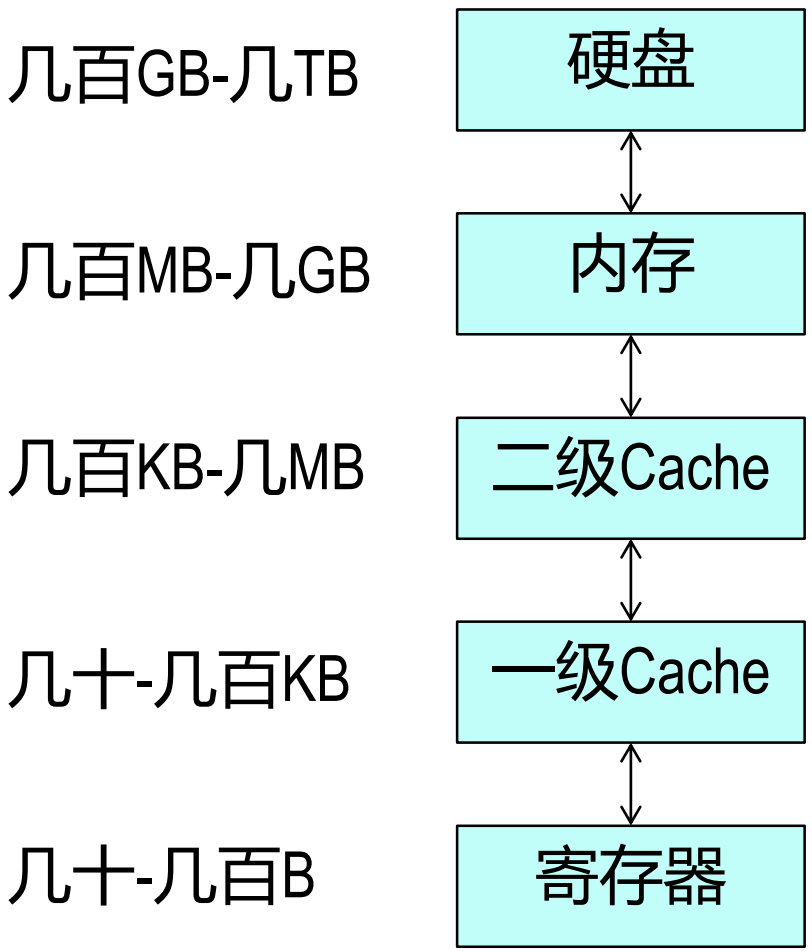

1s = 1000ms
1ms = 1000us
1us = 1000ns

索引的基本概念（Index）

- 索引
  - 记录关键字值与记录的存储位置之间的对应关系
- 索引文件
  - 由基本数据与索引表两部分组成的数据集称为索引文件
- 索引表的特点
  - (1) 索引表是由系统自动产生的
  - (2) 索引表中表项按关键字值有序排列

稠密索引

- 特点：基本数据中的每一个记录在索引表中都占有一项
  - 在稠密索引文件中查找一个记录存在与否的过程是直接查找索引表

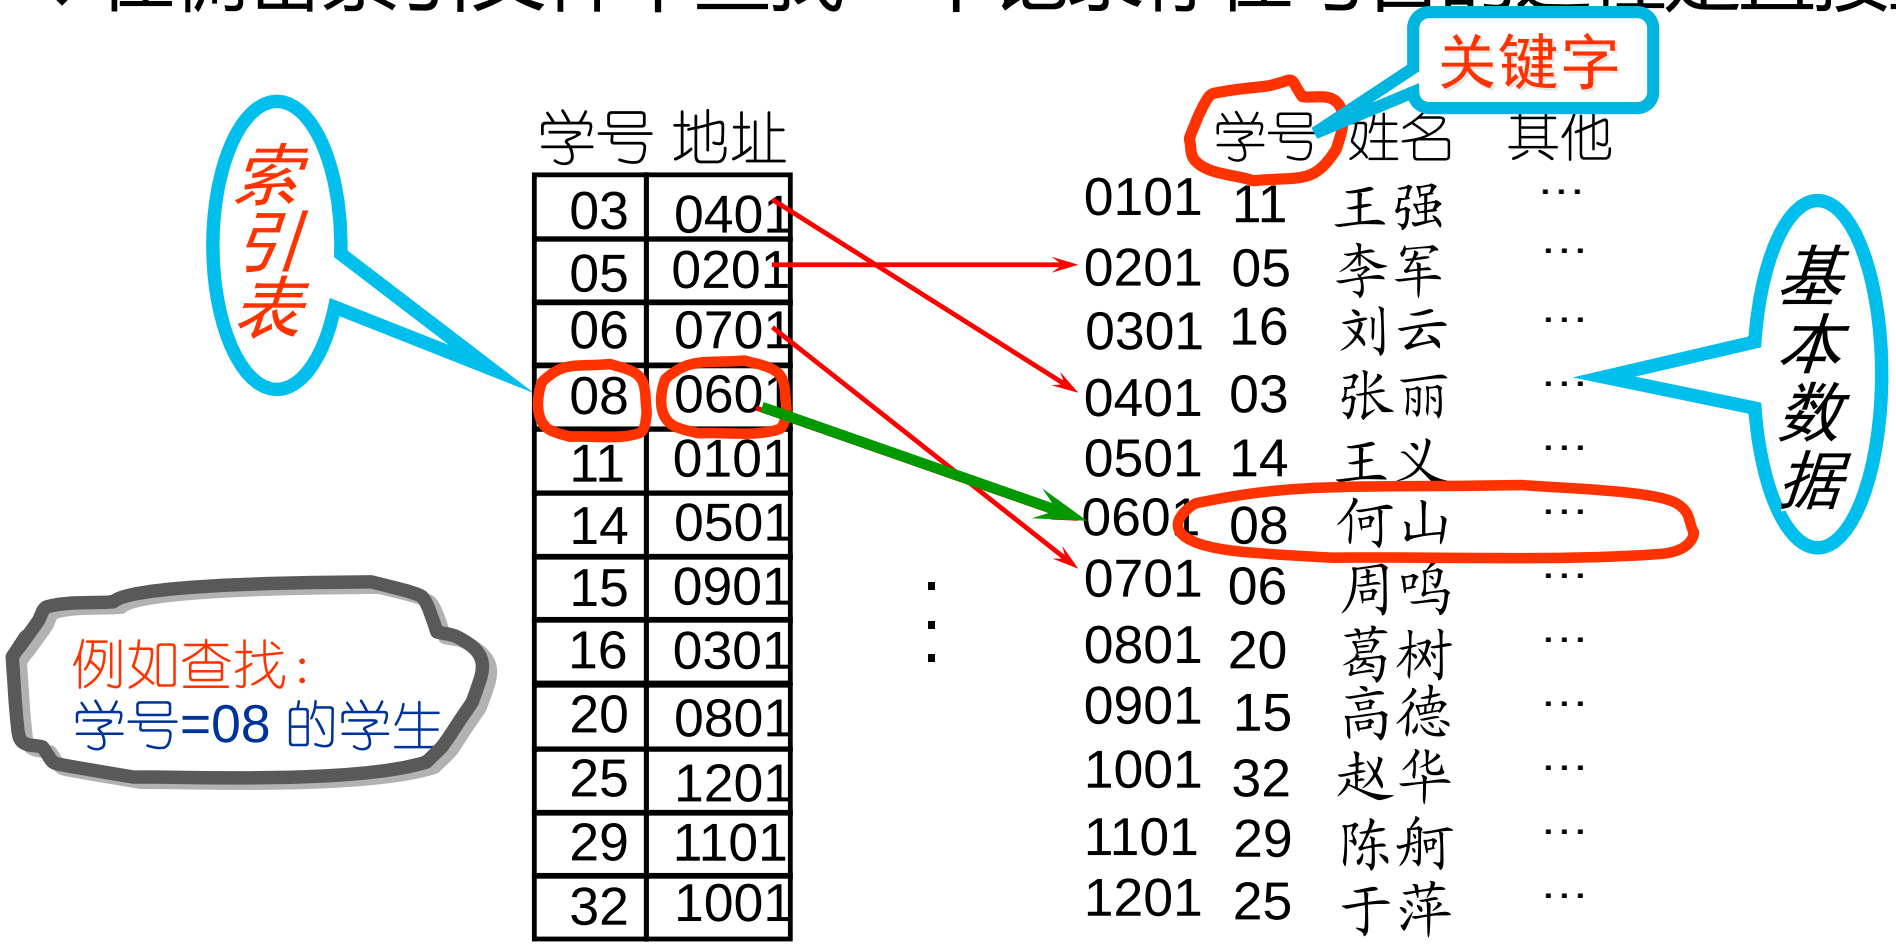

非稠密索引-分块索引

- 将文件的基本数据中记录分成若干块（块与块之间记录按关键字值有序，块内记录是否按关键字值有序无所谓），索引表中为每一块建立一项

非稠密索引的查找

- 在非稠密索引文件中查找一个记录存在与否的过程
  - 先查找索引表（确定被查找记录所在块），然后在相应块中查找被查记录存在与否

多级索引

- 当索引文件的索引本身非常庞大时，可以把索引分块,建立索引的索引，形成树形结构的多级索引
  - 二叉查找树多级索引结构
  - 多叉树（B-、B+）索引结构
- 延伸阅读*：
  - 倒排索引（inverted index）是目前搜索引擎中常用的搜索技术
  - 请同学自学有关倒排索引的基本原理

数据结构与程序设计（信息类）

Data Structure and Programming

第 6 章

查找(Searching)

目录

CONTENTS

6.4 树结构：二叉查找（排序）树（BST）

- 现实应用中，索引文件往往采用树结构来实现
- 二叉查找（排序）树
  - 采用链式存储，元素插入与删除效率高
  - 查找效率通常较高（顺序存储的优点）
    - 平衡二叉排序树AVL的查找算法时间复杂度为$O(\log_2 n)$
  - 适合动态查找表的数据组织（如单词词频统计中单词表的构造）

二叉查找树的查找和插入算法

功能：在一个二叉查找树中查找某个元素。若该元素不存在，则将节点插入到二叉查找树中的相应位置上。（特别适合动态查找表的构造和查找）

```
BTNodeptr searchBST(BTNodeptr t, Datatype key)
{
    BTNodeptr p = t;
    while (p != NULL) {
        if (key == p->data)
            return p;
        if (key > p->data)
            p = p->rchild;
        else
            p = p->lchild;
    }
    return NULL;
}
```

```
BTNodeptr insertBST(BTNodeptr p, Datatype item)
{
    if (p == NULL){
        p = (BTNodeptr)malloc(sizeof(BTNode));
        p->data = item;
        p->lchild = p->rchild = NULL;
    }
    else if (item < p->data)
        p->lchild = insertBST(p->lchild, item);
    else if (item > p->data)
        p->rchild = insertBST(p->rchild, item);
    else
        do-something; //找到该元素
    return p;
}
```

二叉查找树的平衡问题

- BST通常不是一棵平衡树，它的树结构与输入数据的顺序有很大的关系，它很难达到理想的O(log2n)查找性能
- 对于像单词表（字典）的数据，有没有更好的数据结构呢?

输入：do not take to heart every thing you hear

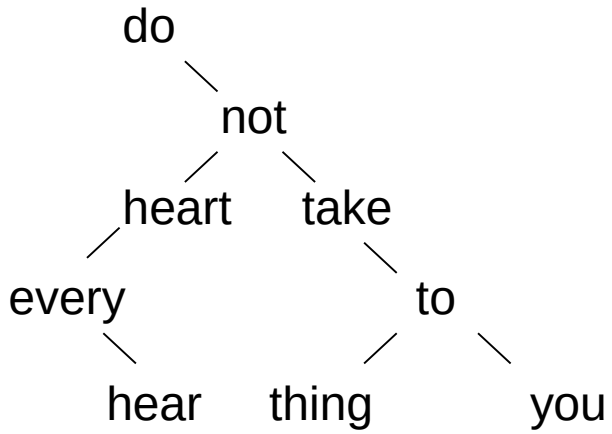

输入：do every hear heart not take thing to you

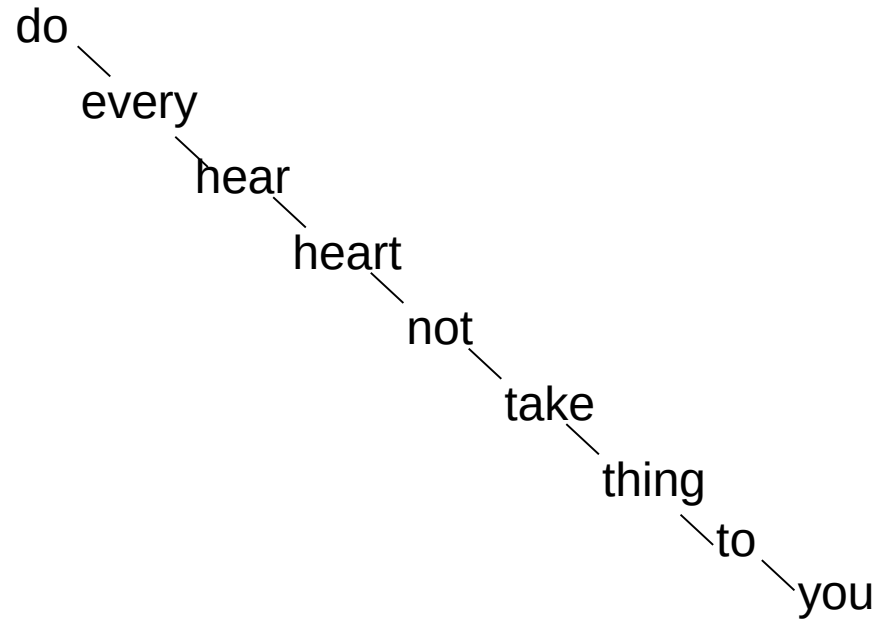

Trie树*

- 在二叉树遍历中通常是通过比较整个键值来进行的，即每个节点包含一个键值，该键值与要查找的键值进行比较来在树中寻找正确的路径
- 用键值的一部分来确定查找路径的树称为trie树（它来源于retrieval）（为了在发音上区别tree，可读作try）
- 主要应用
  - 信息检索（information retrieval）
  - 用来存储英文字符串，特别是大规模的英文词典（在自然语言理解软件中经常用到，如词频统计、拼写检查）

Trie树的使用*

- Trie结构主要基于两个原则：
  - 键值由固定的字符序列组成（如数字或字母），如Huffman码(只由0，1组成)、英文单词（只由26个字母组成）
  - 对应结点的分层标记；
- Trie结构典型应用“字典树”：英文单词仅由26个字母组成(不考虑大小写)
  - 字典树每个内部结点都有26个子结点
  - 树的高度为最长单词长度
- Trie实际上就是一个多叉树结构

Trie树示例

一种用于描述单词的trie结构定义

```
struct tnode { // word tree
    char isword;  // is or not a word
    char isleaf;   // is or not a leaf node
    struct tnode *ptr[26];
};
```

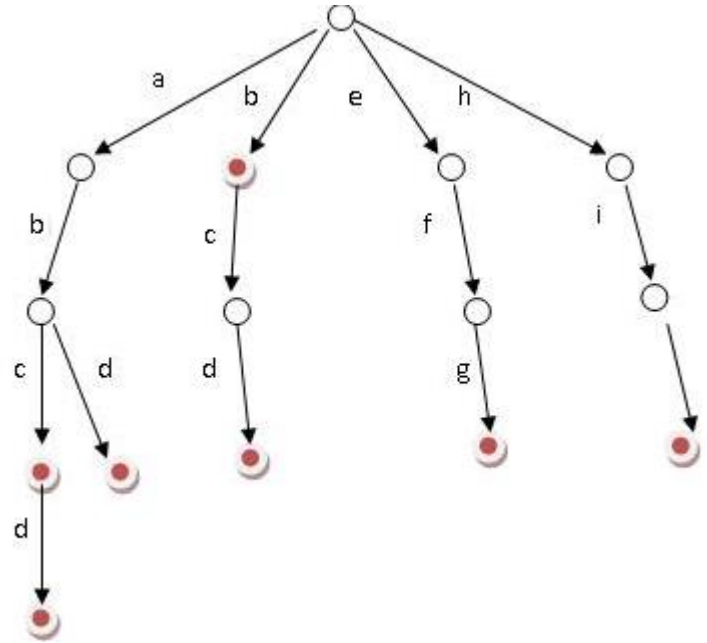


```
//基于trie结构的单词树的构造
void wordTree(struct tnode *root, char *w){
    struct tnode *p;
    for (p = root; *w != '\0'; w++){
        if (p->ptr[*w - 'a'] == NULL) {
            p->ptr[*w - 'a'] = talloc();
            p->isleaf = 0;
        }
        p = p->ptr[*w - 'a'];
    }
    p->isword = 1;
}
struct tnode *talloc(){
    int i;
    struct tnode *p;
    p = (struct tnode *)
        malloc(sizeof(struct tnode));
    isword = 0;   isleaf = 1;
    for (i = 0; i < 26; i++)
        ptr[i] = NULL;
    return p;
}
```

Trie结构性能分析

- 采用Trie结构，对英文单词来说，树的高度取决于最长单词长度
  - 绝大多数常用单词通常都不是很长，一般访问几个节点（很可能是5~7个）就可以解决问题
- 而采用（最理想的）平衡二叉查找树，假设有10000个单词，则树的高度为14（lg10000）
  - 由于大多数的单词都存储在树的最低层，因此平均查找单词需要访问13个节点，是Trie树的两倍
- 此外，在BST树中，查找过程需要比较整个单词（串比较），而在trie结构中，每次比较只需要比较一个字母
- 在访问速度要求很高的系统中，如拼写检查、词频统计中，trie结构是一个非常好的选择

6.4 多路查找树：B-树和B+树

- B-树：一个m阶的B-树为满足下列条件的m叉树
  - (1) 每个分支结点最多有m 棵子树
  - (2) 除根结点外，每个分支结点最少有$\lceil m/2 \rceil$棵子树；
  - (3) 根结点最少有两棵子树(除非根为叶结点,此时B-树只有一个结点)；
  - (4) 所有“叶结点”都在同一层上，叶结点不包含任何关键字信息（可以把叶结点视为实际上不存在的外部结点,指向“叶结点”的指针为空)；
  - (5) 所有分支结点中包含下列信息：

    $n,\ p_0,\ key_1,\ p_1,\ key_2,\ p_2,\ \ldots,\ key_n,\ p_n$

  - 其中,n为结点中关键字值的个数, $n \le m-1$
    - key_i为关键字，且满足 $key_i < key_{i+1}$，$1 \le i < n$
    - p_i为指向该结点的第i+1棵子树的根的指针，$0 \le i \le n$

一颗4阶B-树

一棵4阶B-树

- 每个分支结点最多有4棵子树（即最多有m-1个关键字值）
- 每个分支结点最少有2棵子树
- 根结点最少有2棵子树
- 所有“叶结点”都在同一层上

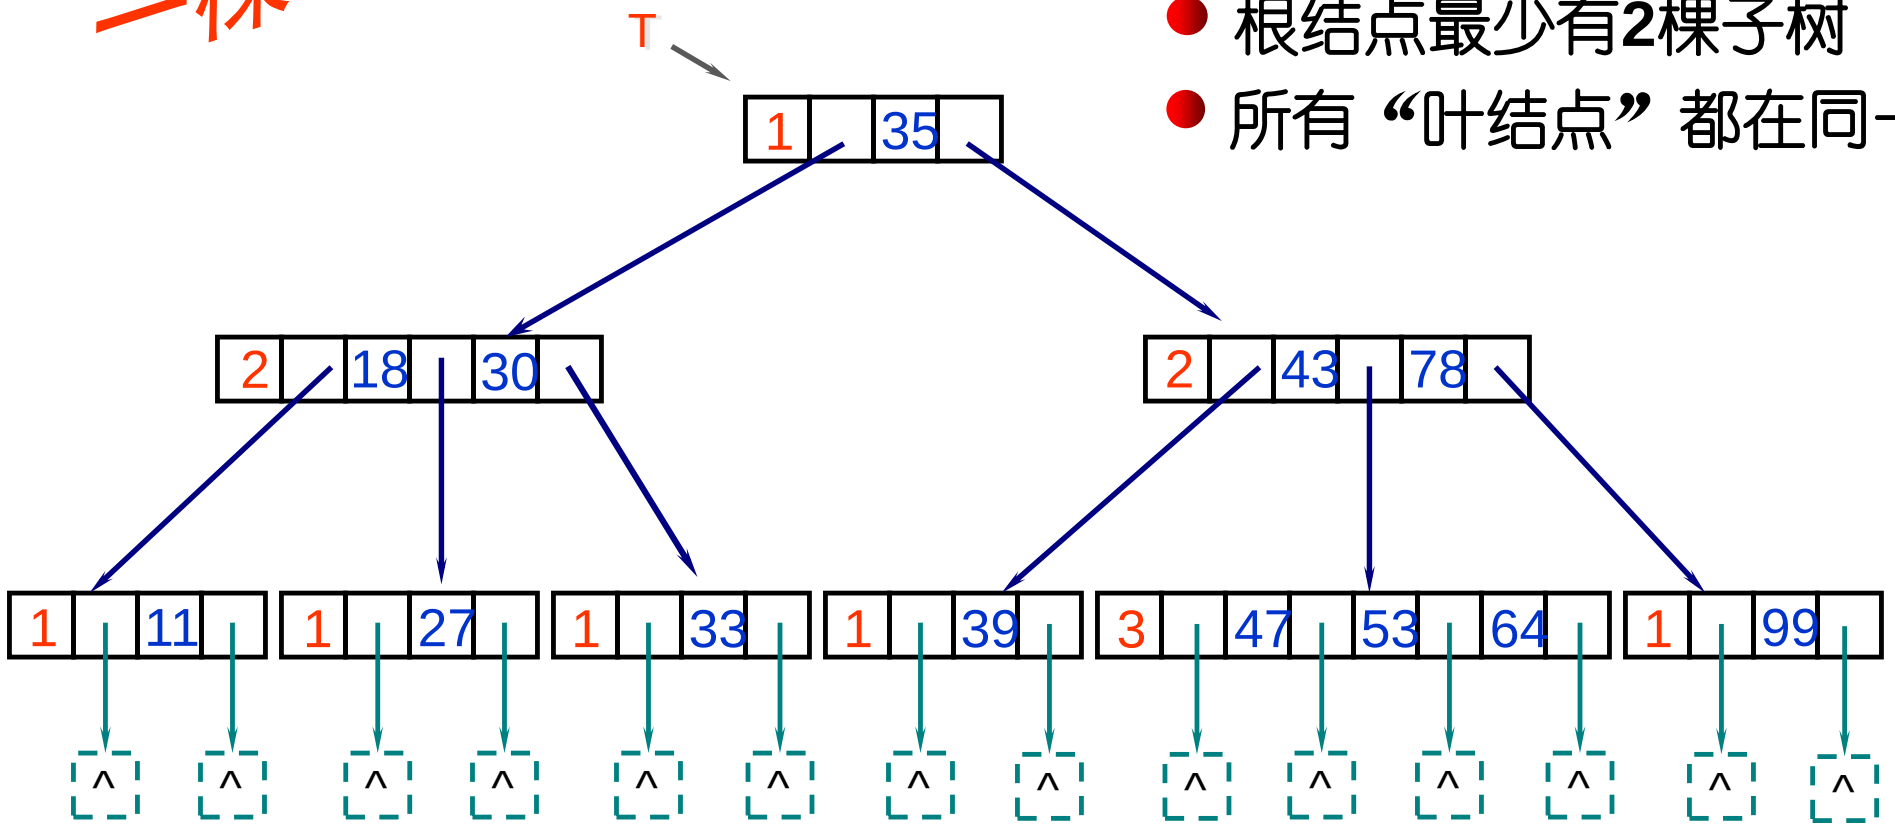

B-树的查找

类似于二叉排序树的查找

首先将给定的关键字k在B-树的根结点的关键字集合中采用**顺序查找法**或**折半查找法**进行查找，若有$k=key_i$，则查找成功，根据相应的指针取得记录。否则，若$k<key_i$,则在指针p_{i-1}所指的结点中重复上述查找过程,直到在某结点中查找成功，或者有$p_{i-1}=NULL$，查找失败

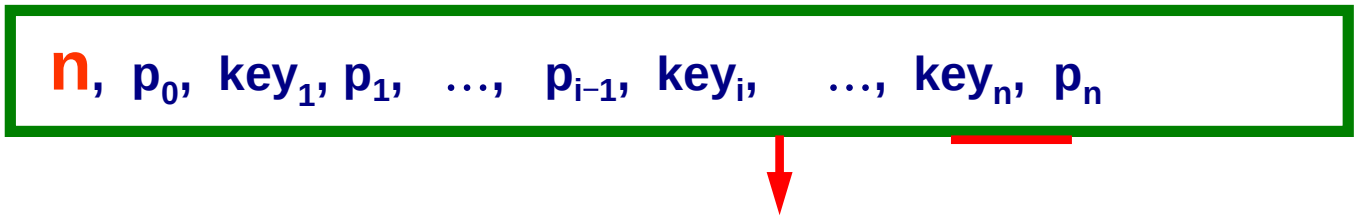

示例：4阶B-树

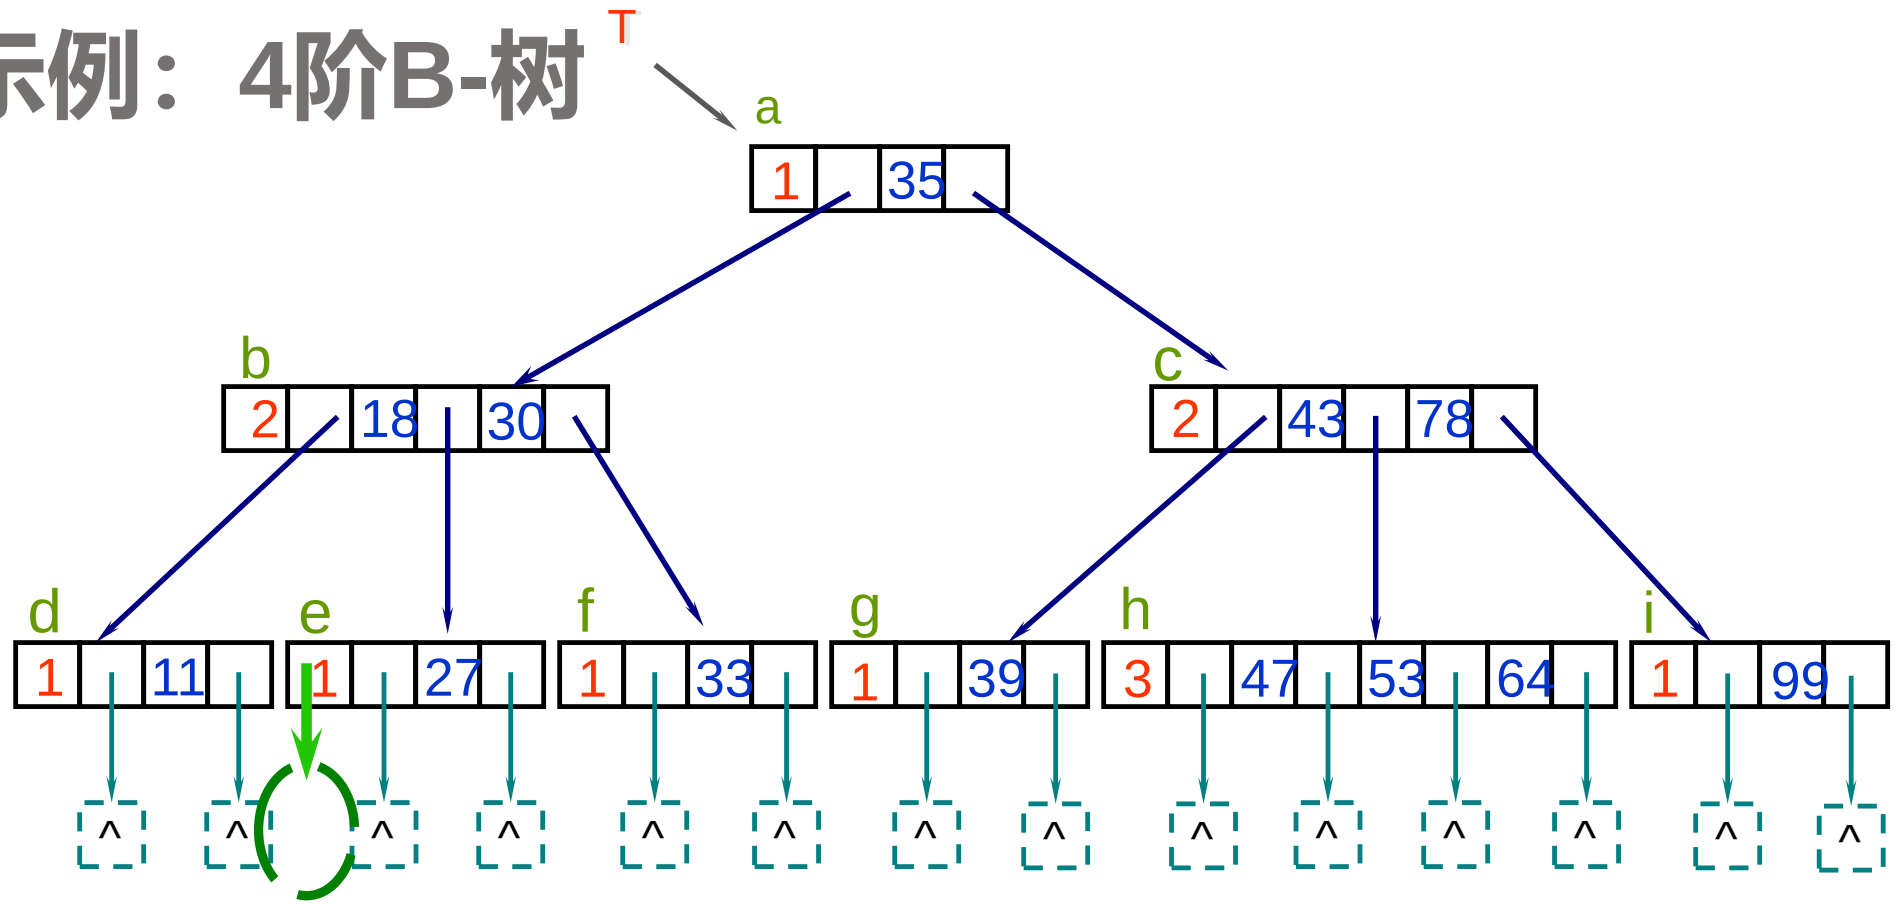

例如，查找关键字值k=47　　查找成功！

例如，查找关键字值k=23　　查找失败！

原则
(1) $k=key_i$　查找成功
(2) $k<key_i$　在p_{i-1}所指的结点中查找

B-树的查找过程

```
keytype searchBTree(BNode *t, keytype k){
    int i, n;
    BNode *p = t;
    while (p != NULL)
    {
        n = p->keynum;
        p->key[n + 1] = Maxkey;
        i = 1;
        while (k > p->key[i])
            i++;
        if (p->key[i] == k)
            return p->key[i];
        else
            p = p->ptr[i - 1];
    }
    return -1;
}
```

在p指结点的关键字集合中查找k

```
#define M 1000
typedef struct node {
        int   keynum;
        keytype   key[M+1];
        struct node   *ptr[M+1];
        rectype   *recptr[M+1];
} BNode;
```

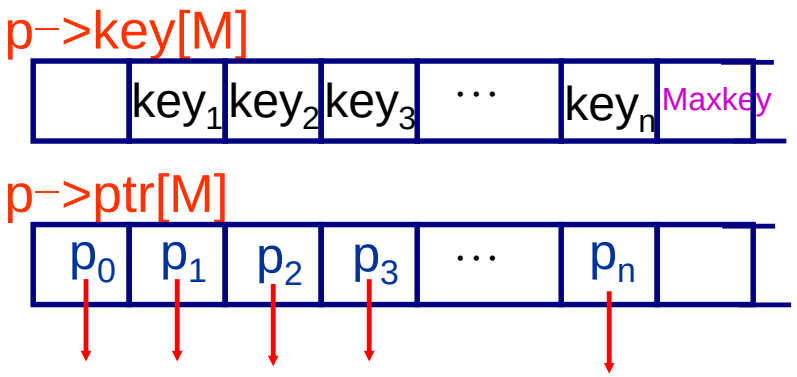

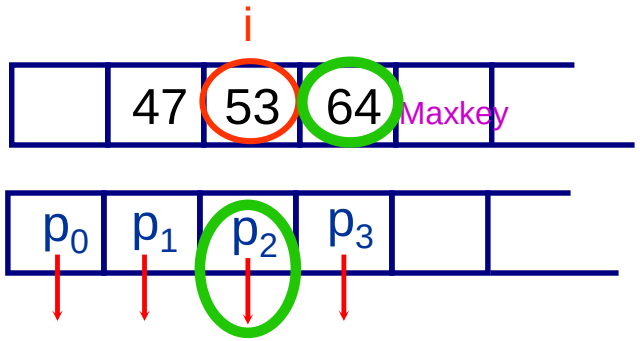

k=62

沿着新的指针p_2继续查找！

k=53

查找成功！

B-树的插入

- B-树的生成从空树开始，即逐个在叶结点中插入结点(关键字)而得到

一棵3阶B-树

插入 k=15

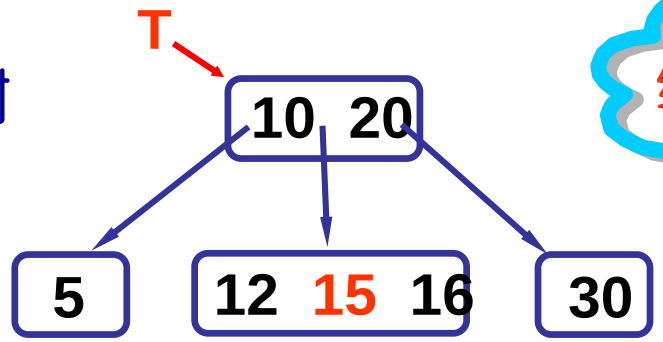

一棵m阶B-树的结点中最多有m−1个关键字值！

结点分裂

基本思想

若将k插入到某结点后使得该结点中关键字值数目超过m-1时，则要以该结点**位置居中**的那个关键字值为界将该结点**一分为二**，产生一个新结点，并把位置居中的那个关键字值插入到双亲结点中；如双亲结点也出现上述情况，则需要再次进行分裂. 最坏情况下，需要一直分裂到根结点，以致于使得B-树的深度加1。

结点分裂

一般情况下

若某结点已有m−1个关键字值，在该结点中插入一个新的关键字值，使得该结点内容为

q

m	key_1	key_2	key_3	…	key_i	key_{i+1}	…	key_{m-1}	key_m

则需要将该结点分解为两个结点q′与q ，即

q

$\lceil m/2 \rceil-1$	key_1	key_2	…	$key_{\lceil m/2 \rceil-2}$	$key_{\lceil m/2 \rceil-1}$

q′

$m-\lceil m/2 \rceil$	$key_{\lceil m/2 \rceil+1}$	$key_{\lceil m/2 \rceil+2}$	…	key_{m-1}	key_m

并且将关键字值$key_{\lceil m/2 \rceil}$与一个指向q 的指针插入到q的双亲结点中。

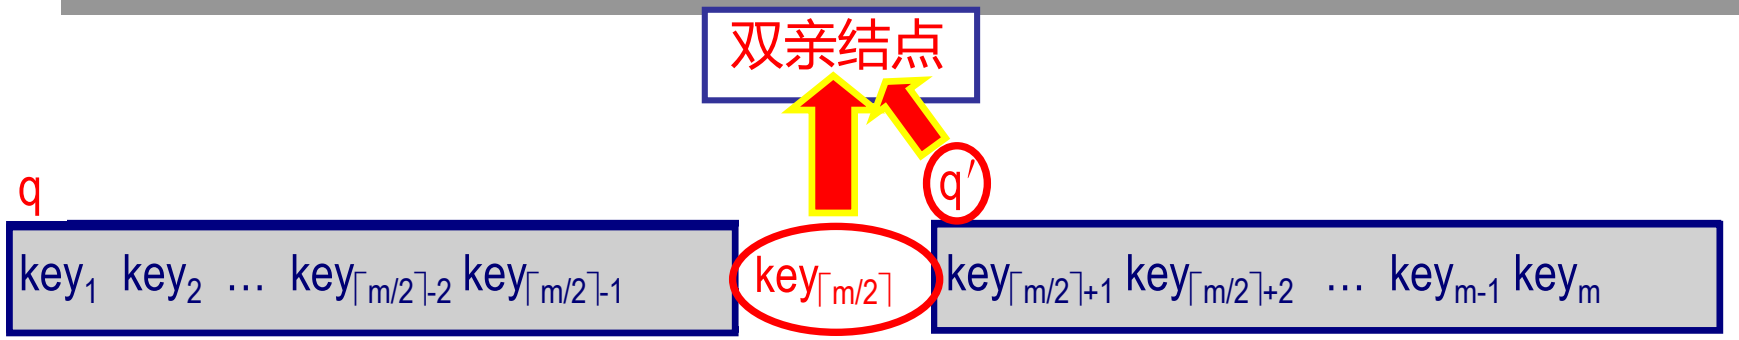

结点分裂示例

3阶B-树　插入15

每个分支结点中
关键字个数< 3

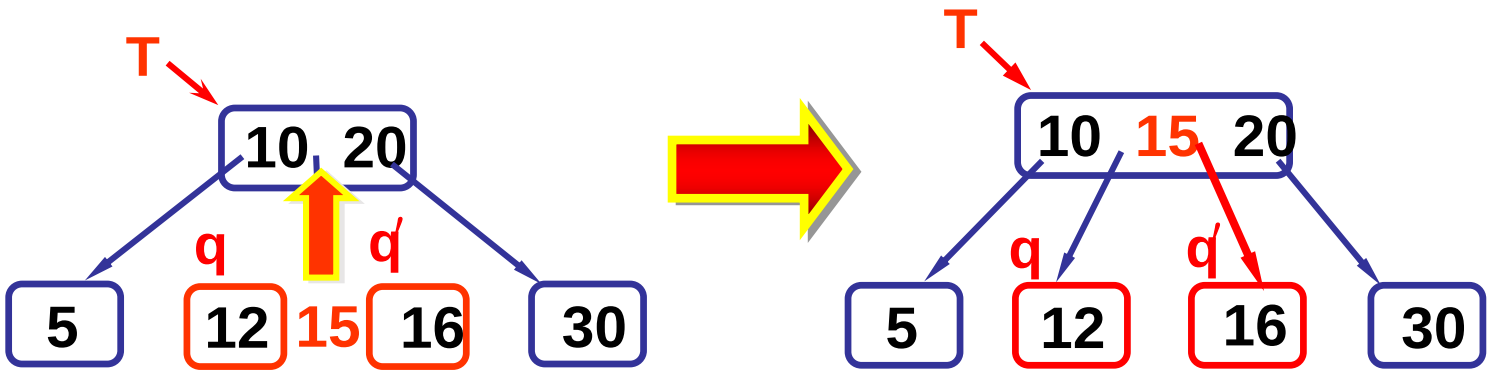

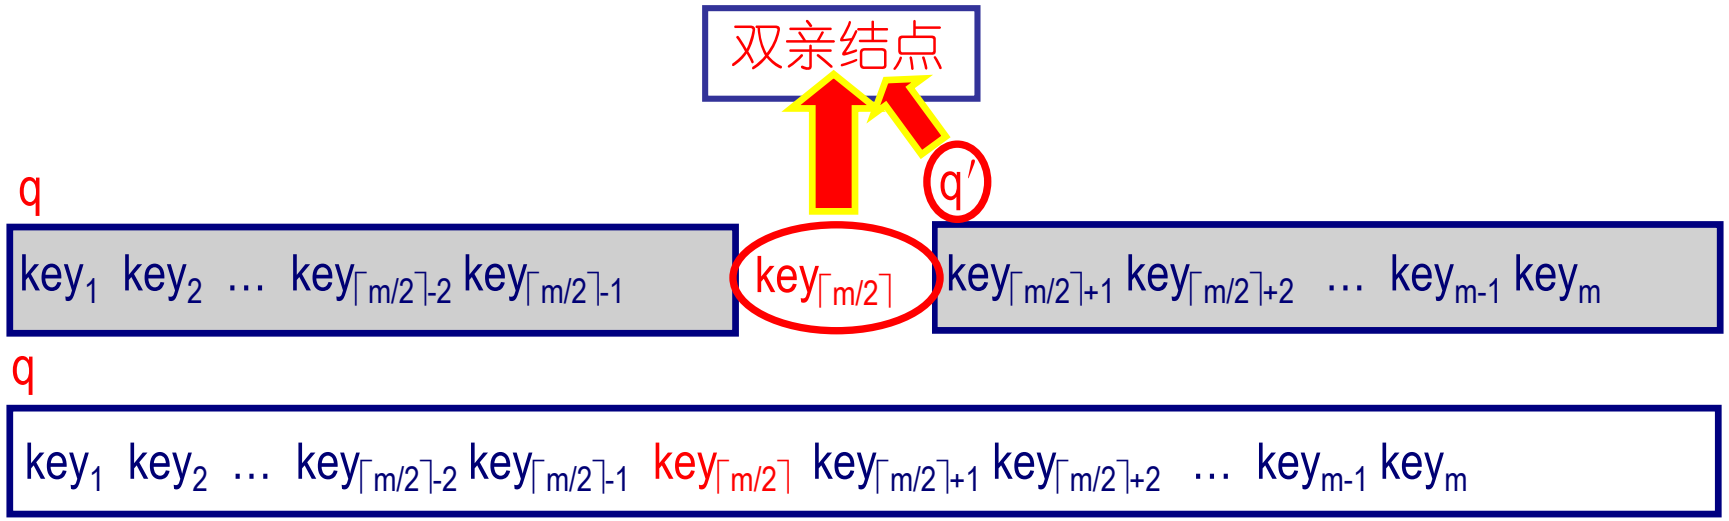

练习：构造B-树

请画出依次插入关键字序列(5,6,9,13,8,1,12,4,3,10)中各关键字值以后的4阶B-树

B-树的生成从空树开始，即逐个在叶结点中插入结点(关键字)而得到

原则

1. 4阶B-树的每个分支结点中关键字个数不能超过3；
2. 生成B-树从空树开始，逐个插入关键字而得到的；
3. 每次在最下面一层的某个分支结点中添加一个关键字;若添加后该分支结点中关键字个数不超过3，则本次插入成功，否则，进行结点分裂。

练习：B-树

(5, 6, 9, 13, 8, 1, 12, 14, 10, 4, 3)

4阶B-树

结点分裂

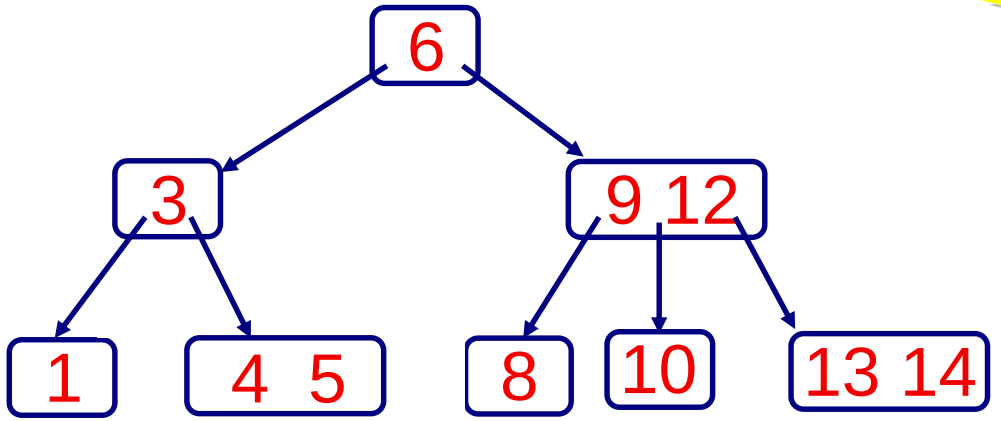

B+树

- 一个m阶的B+树为满足下列条件的m叉树：

同B-树

(1) 每个分支结点最多有m 棵子树；

(2) 除根结点外，每个分支结点最少有$\lceil m/2 \rceil$棵子树；

(3) 根结点最少有两棵子树(除非根为叶结点结点,此时B+树只有一个结点)；

(4) 具有n 棵子树的结点中一定有n 个关键字；

(5) 叶结点中存放记录的关键字以及指向记录的指针,或者数据分块后每块的最大关键字值及指向该块的指针，并且叶结点按关键字值的大小顺序链接成线性链表。

key_1	p_1	key_2	p_2	……	key_n	p_n

(6) 所有分支结点可以看成是索引的索引，结点中仅包含它的各个孩子结点中最大(或最小)关键字值和指向孩子结点的指针。

一颗3阶B+树

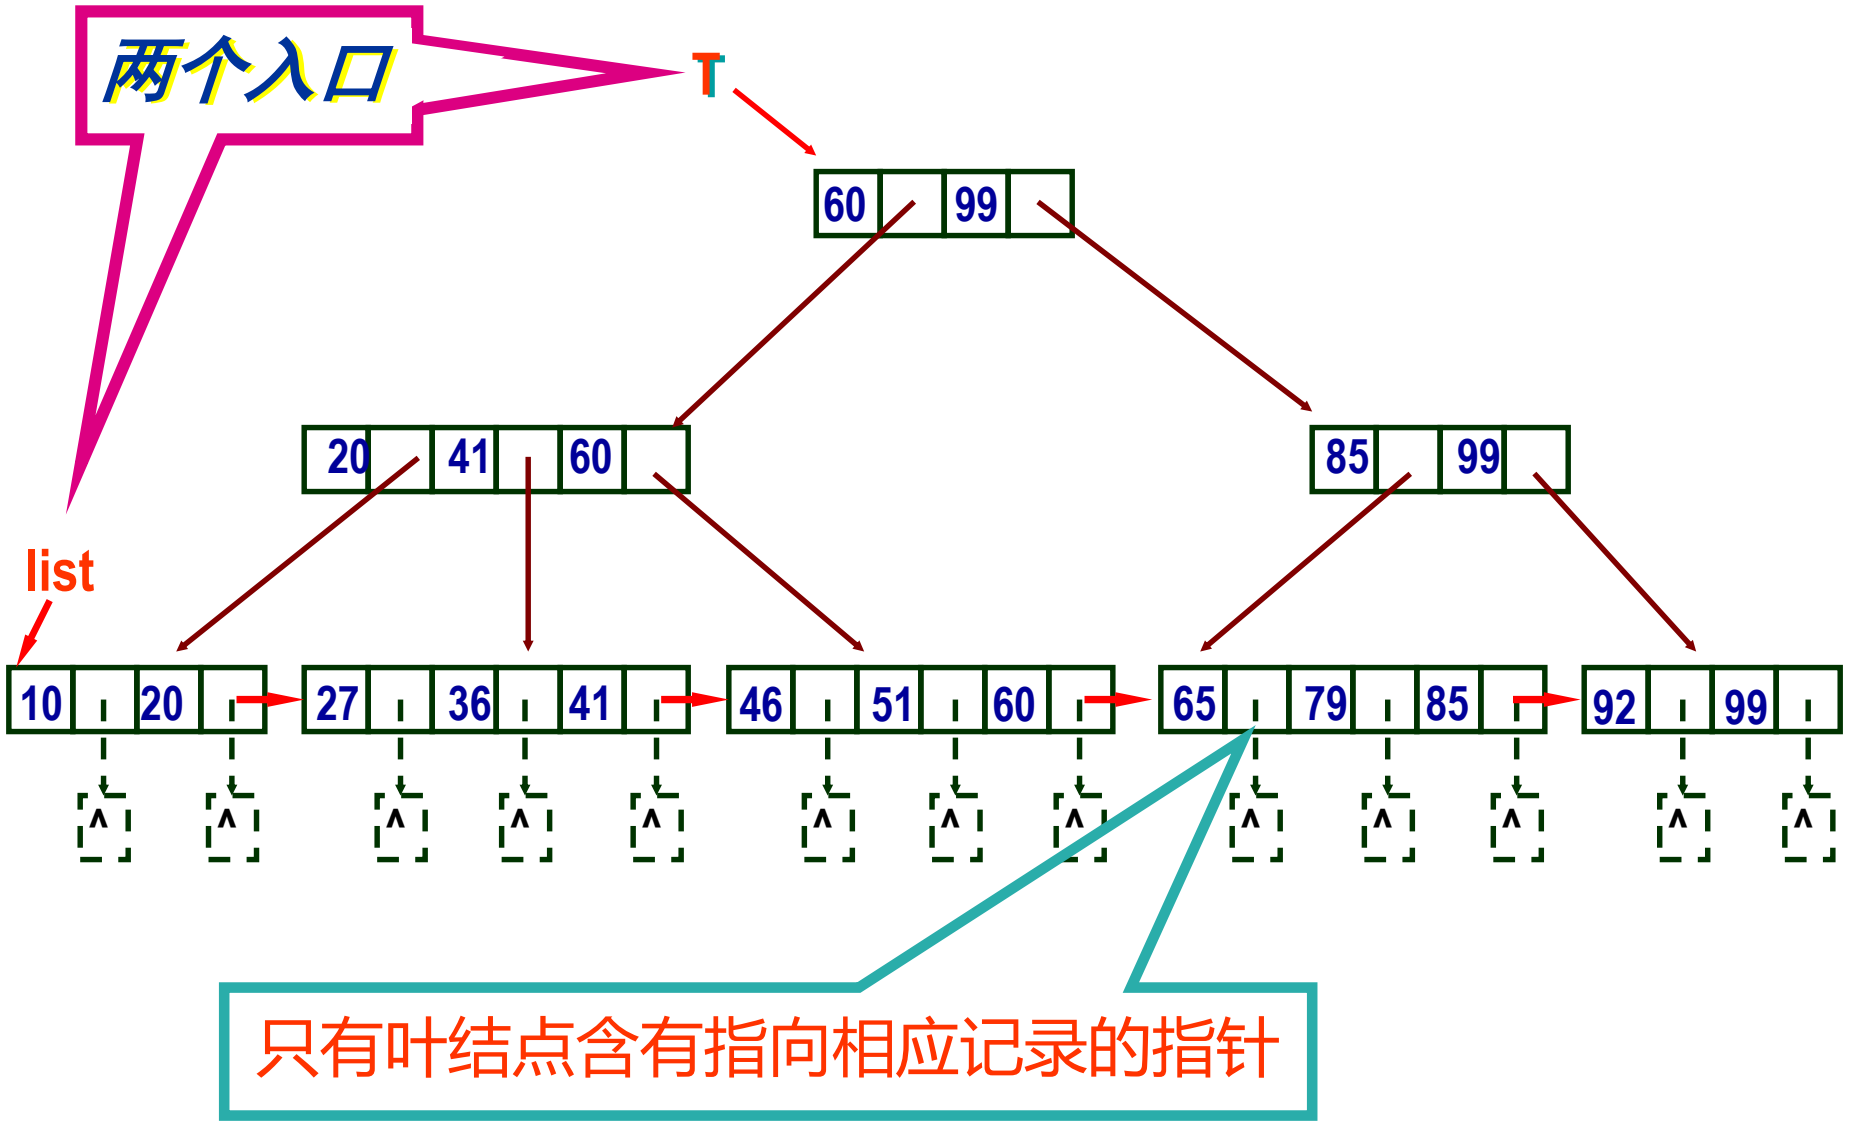
两个入口
T
60
99
20
41
60
85
99
list
10
20
27
36
41
46
51
60
65
79
85
92
99
只有叶结点含有指向相应记录的指针

B-树与B+树

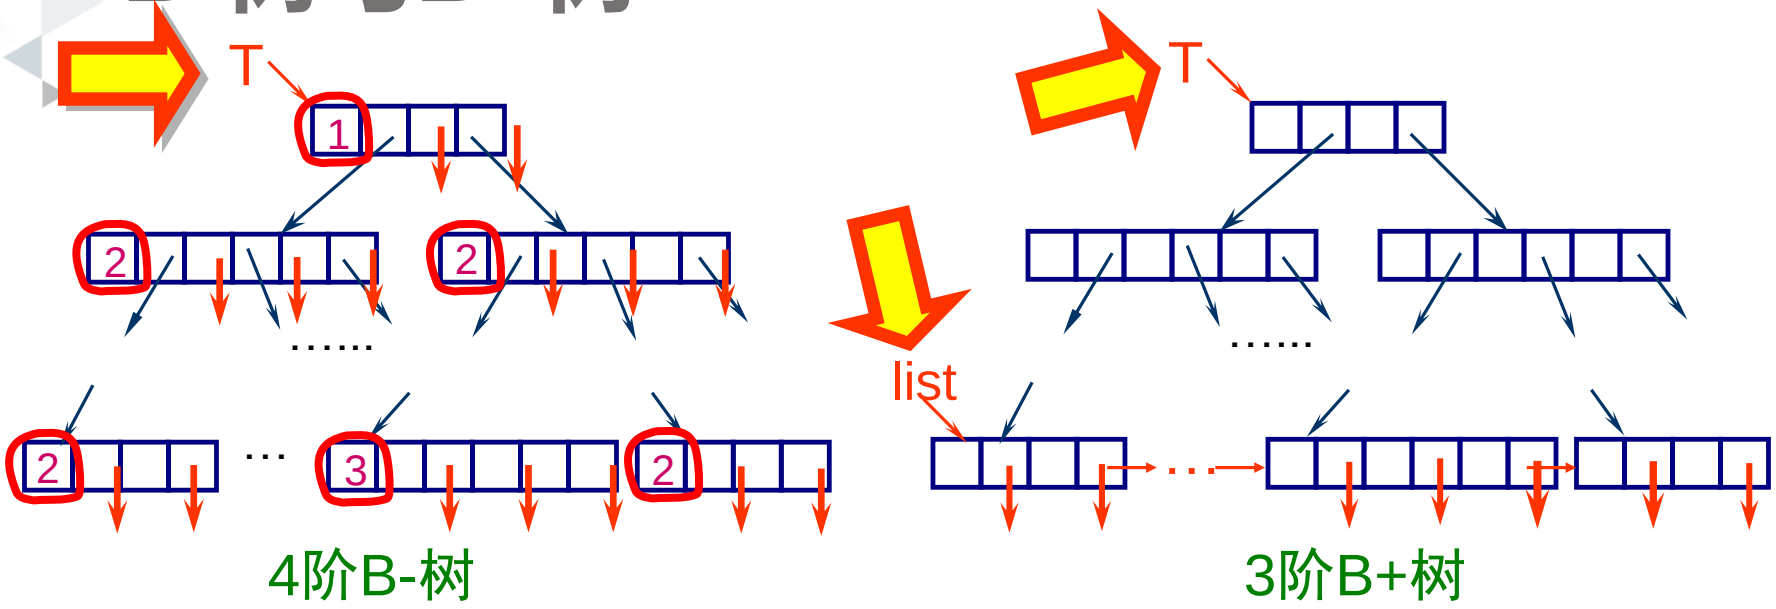

B-树与B+树的区别 （从结构上看）

1.B-树的每个分支结点中含有该结点中关键字值的个数,B+树没有；

2. B-树的每个分支结点中含有指向关键字值对应记录的指针，而B+ 树只有叶结点有指向关键字值对应记录的指针；

3. B-树只有一个指向根结点的入口，而B+树的叶结点被链接成为一 个不等长的链表， 因此，B+树有两个入口，一个指向根结点，另一个指向最左边的叶结点(即最小关键字所在的叶结点)。

B-树和B+树的应用

- B-树是1970年由R.Bayer和E.MacCreight提出的，是一种平衡的多路树
  - 为什么叫B-树，有人认为是由“平衡(Balanced)”而来，而更多认为是因为他们是在Boeing科学研究实验发明的此概念并以此命名的
  - B-树多用于文件系统或数据库系统的索引结构
- B*树
  - B+树的变体，在B+树的非根和非叶子结点再增加指向兄弟的指针

数据结构与程序设计（信息类）

Data Structure and Programming

第 6 章

查找(Searching)

目录

CONTENTS

6.5 散列（Hash）查找

- 基于关键字比较的查找方法
  - 顺序查找、折半查找、索引查找都是通过比较关键字找到结点
  - 查找的时间效率主要取决于查找过程中进行的比较次数
- 散列（Hash，哈希）表：基于数学运算的查找
  - 散列表是计算机科学里的一个伟大发明
  - 它是由数组、链表和一些数学方法相结合，构造起来的一种能够高效支持动态数据的存储和查找的结构，在程序设计中经常使用
  - 利用数学运算函数直接建立记录关键字与存储位置之间的关系
    - 不经过任何关键字值的比较或者经过很少次的关键字值的比较

散列函数

$$A = H(k)$$

其中，k 为记录的关键字，H(k)称为散列函数，或哈希(Hash)函数，或杂凑函数，函数值A为k对应的记录在查找表中位置

关键字

学号	姓名	性别	…
99001	张 云	女	…
99002	王 民	男	…
99003	李 军	男	…
99004	汪 敏	女	…
……	…	…	…
99030	刘小春	男	…

1	张 云 …
2	王 民 …
3	李 军 …
4	汪 敏 …
:	……
30	刘小春 …

地址范围: [1..30]

散列函数： H(k)=k–99000

冲突

- 可能会存在不同关键字的散列值相同的情况

学 号	姓名	性别	…
99001	张 云	女	…
99002	王 民	男	…
99003	李 军	男	…
99004	汪 敏	女	…
……	…	…	…
99030	刘小春	男	…

地址范围：[1..30]

地址冲突

1	李 军 …
2	张 云 …
3	
4	王汪 民敏……
:	……
30	

H(张云)=2
H(王民)=4
H(李军)=1
H(汪敏)=4

选择一种处理冲突的方法

一个处理过程

散列函数：

H(k) = “将组成关键字k的串转换为一个1—30之间的代码”

散列冲突和散列表

- 散列冲突：对于不同的关键字k_i与k_j，经过散列得到相同的散列地址，即有：$H(k_i) = H(k_j)$
  - k_i与k_j称为同义词
- 散列表
  - 根据构造的散列函数与处理冲突的方法将一组关键字映射到一个有限的连续地址集合上，并以关键字在该集合中的“象”作为记录的存储位置，按照这种方法组织起来表称为散列表（哈希表，杂凑表）
  - 建立表的过程称为哈希造表（散列），得到的存储位置称为散列地址或者杂凑地址

散列表的构造

- 基本原则（“好”的散列函数）
  - 散列函数的定义域必须包括将要存储的全部关键字；若散列表允许有m个位置时，则函数的值域为[0 .. m–1](地址空间)
  - 利用散列函数计算出的地址应能尽可能均匀分布在整个地址空间中
  - 散列函数应该尽可能简单，应该在较短的时间内计算出结果
- 基本步骤
  - 确定散列的地址空间（地址范围）
  - 构造合适的散列函数
  - 选择处理冲突的方法

散列函数的构造方法

- 直接定址法
  - 如：H(k) = a k + b
- 数字分析法、平方取中法、叠加法、基数转换法
- 除留余数法
  - H (k) = k MOD p
  - 若m为地址范围大小（即表长），则p可为小于等于m的素数
- 推荐：各种高效的字符串Hash算法（大部分基于位运算）
  - BKDRHash，APHash，DJBHash，JSHash，RSHash，SDBMHash，PJWHash，ELFHash…
  - https://www.cnblogs.com/dongsheng/articles/2637025.html

冲突处理方法

- 所谓处理冲突,是在发生冲突时,为冲突的元素找到另一个散列地址以存放该元素
  - 如果找到的地址仍然发生冲突，则继续为发生冲突的这个元素寻找另一个地址，直到不再发生冲突

1. 开放地址法 — 闭散列方法

所谓开放地址法是在散列表中的“空”地址向处理冲突开放。即当散列表未满时，处理冲突需要的“下一个”地址在该散列表中解决

$$D_i = (H(k) + d_i) \text{ MOD } m \qquad i=1, 2, 3, \ldots$$

其中，H(k)为哈希函数，m为表长，d_i为地址增量，有：

(1) $d_i=1, 2, 3, \ldots, m-1$ 称为线性探测再散列

(2) $d_i=1^2, -1^2, 2^2, -2^2, \ldots,$ 称为二次探测再散列

(3) d_i=伪随机数序列 称为伪随机再散列

开放地址法冲突处理

设散列函数为

$$H(k) = k \ \ MOD \ \ 13$$

除留余数法

散列表为[0..12],表中已分别有关键字为19,70,33的记录，现将第四个记录(关键字值为18)插入散列表中

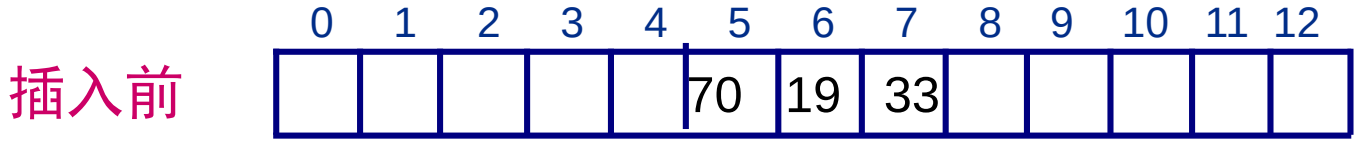

$$D_i = (k \ \ MOD \ \ 13 + d_i) \ \ MOD \ \ 13$$

散列地址为5

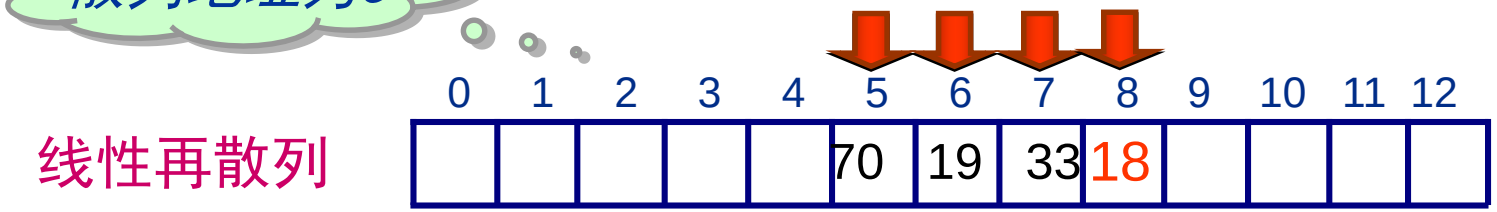

d_i=1, 2, 3, …, m–1

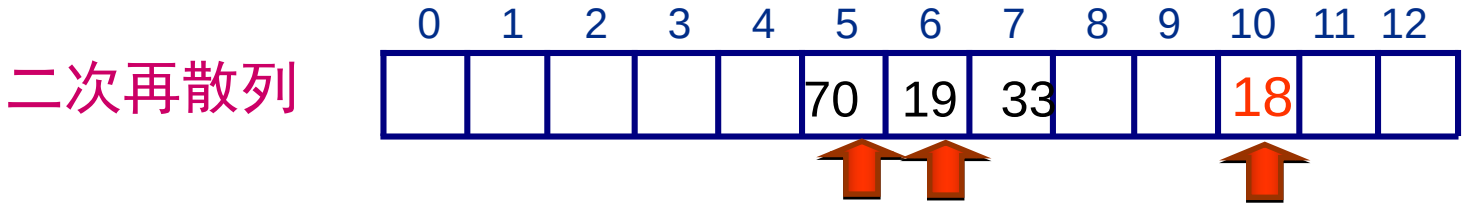

$d_i=1^2, -1^2, 2^2, -2^2, \ldots$

查找过程

采用线性探测再
散列方法处理冲突

散列函数：H(k)=k MOD 13

$D_i = (k \ MOD \ 13 + d_i) \ MOD \ 13$

HT:

0	1	2	3	4	5	6	7	8	9	10	11	12
13	38				70	19	33	18				25

key=70　key=18　key=38　key=20

聚集

- 聚集：散列地址不同的元素争夺同一个后继散列地址的现象
- 产生聚集的主要原因
  - 散列函数选择不合适
  - 负载因子过大（装填因子）
- 负载因子α：衡量散列表的饱满程度
  - 一般情况下$\alpha<1$， α越大，散列表越满

$$\alpha = \frac{\text{散列表中实际存入的元素数}}{\text{散列表中基本区的最大容量}}$$

开放地址法处理冲突的特点

- “线性探测法”容易产生元素“聚集”的问题
- “二次探测法”可以较好地避免元素“聚集”的问题，但不能探测到表中的所有元素(至少可以探测到表中的一半元素)
- 只能对表项进行逻辑删除(如做删除标记)，而不能进行物理删除。使得表面上看起来很满的散列表实际上存在许多未用位置

其他冲突处理方法

- 2. 再散列法
  - $D_i = H_i(k)$　　i=1, 2, 3, …
  - 其中，D_i为散列地址，$H_i(k)$为不同的散列函数
- 3. 链地址法
  - 将所有散列地址相同的记录链接成一个线性链表。
  - 若散列范围为[0..m-1]，则定义指针数组bucket[0..m-1]分别存放m个链表的头指针

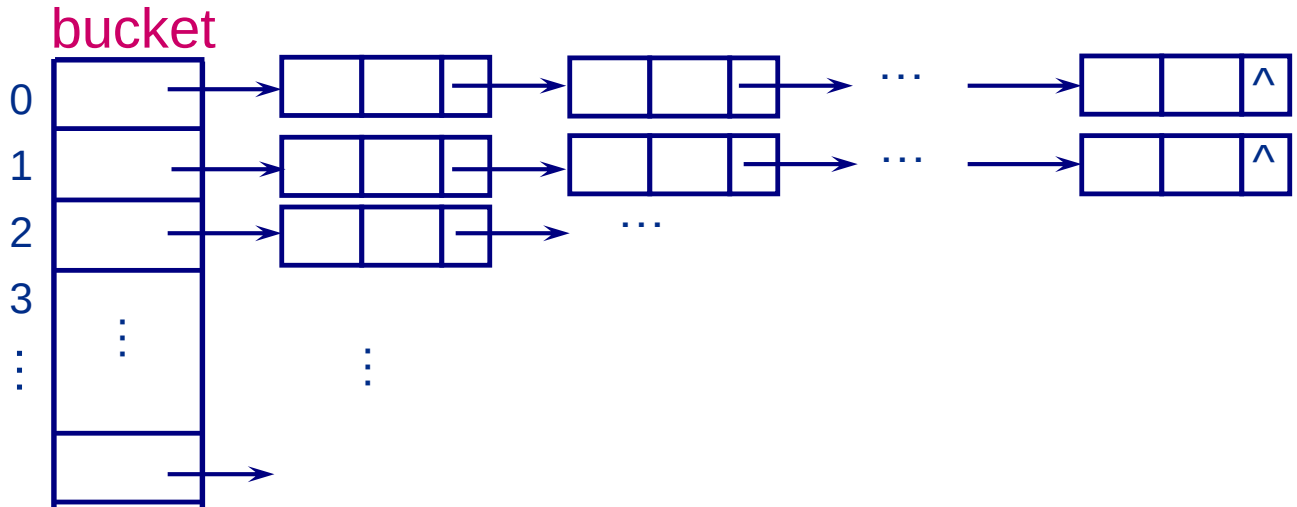

链地址法处理冲突

设散列函数为

$$H(k) = k \ \ MOD \ \ 10$$

散列表为[0..9],采用链地址法处理冲突,画出关键字序列{75, 66, 42, 192, 91, 40, 49, 87, 67, 16, 17, 30, 72, 27}对应的记录插入散列表后的散列文件

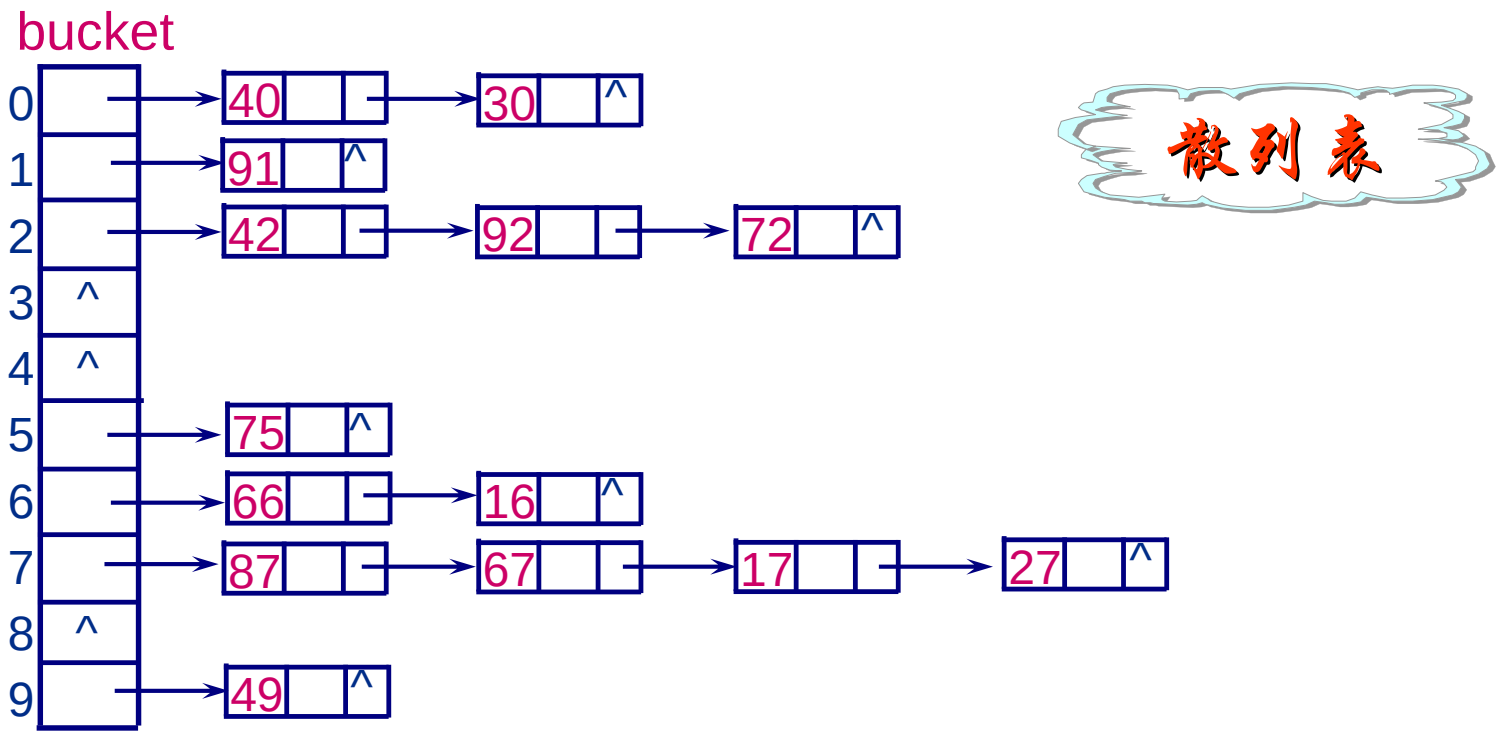

链地址法特点

- 处理冲突简单，不会产生元素“聚集”现象，平均查找长度较小
- 适合建立散列表之前难以确定表长的情况
- 建立的散列表中进行删除操作简单
- 由于指针域需占用额外空间，当规模较小时，不如“开放地址法”节省空间

散列表的典型应用

- 散列表的一个典型应用是符号表（symbol），用于在数据值和动态符号（如变量名，关键码）集的成员间建立一种关联
  - 符号表是编译系统中主要的数据结构，用于管理用户程序中各个变量的信息，通常编程系统使用散列表来组织符号表
  - 散列表的思想就是把关键码送给一个散列函数，以产生一个散列值，这种值通常平均分布在一个适当的整数区间中，用作存储信息的表的下标
  - 常见做法是为每一个散列值关联一个数据项的链表，这此项共有同一个散列值（散列冲突）
- 散列表还常用于浏览器中维持最近使用的页面踪迹、缓存最近使用过的域名及它们的IP地址

词频统计-利用散列查找提高链表实现查找效率

- 链表实现方式插入算法简单效率高，但查找效率低，有没有方法能提高单词的查找效率?

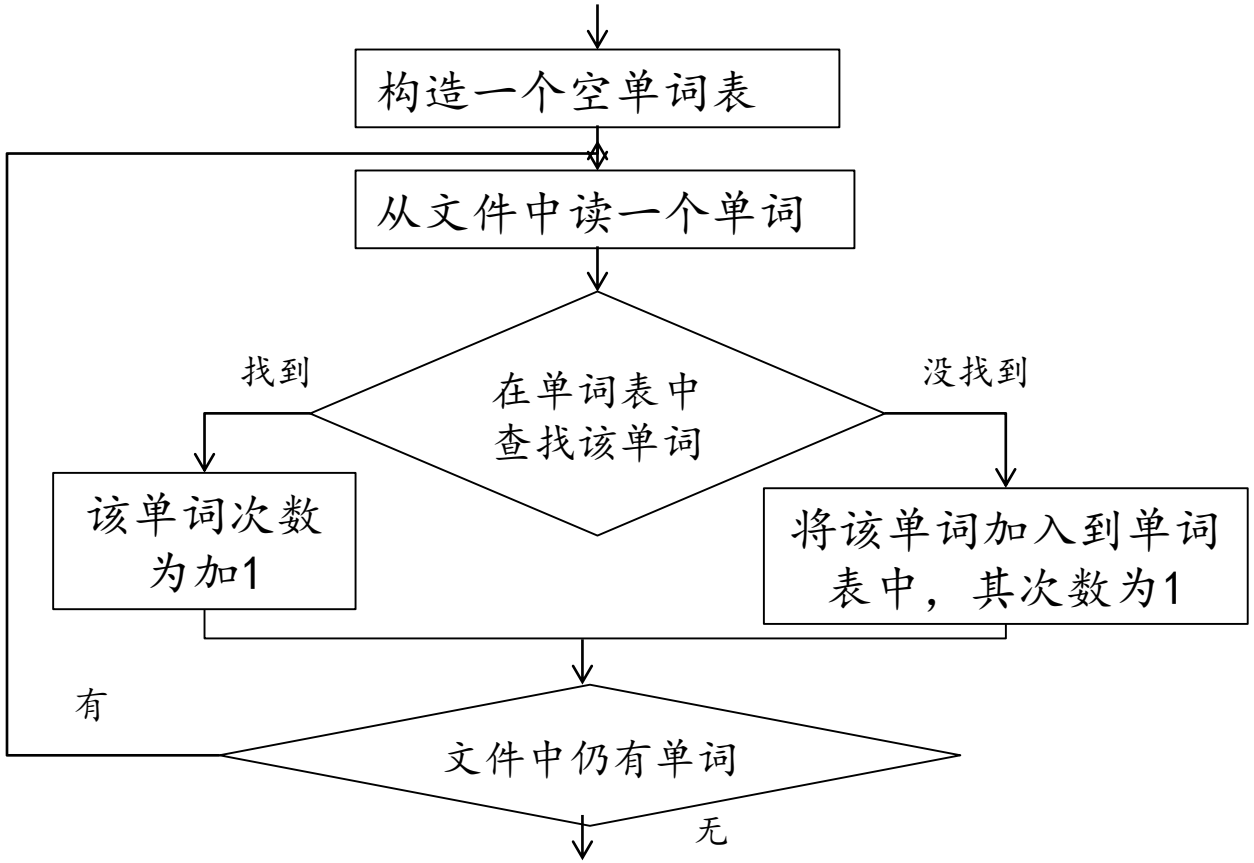

散列表的设计与实现

1.Hash表的构建

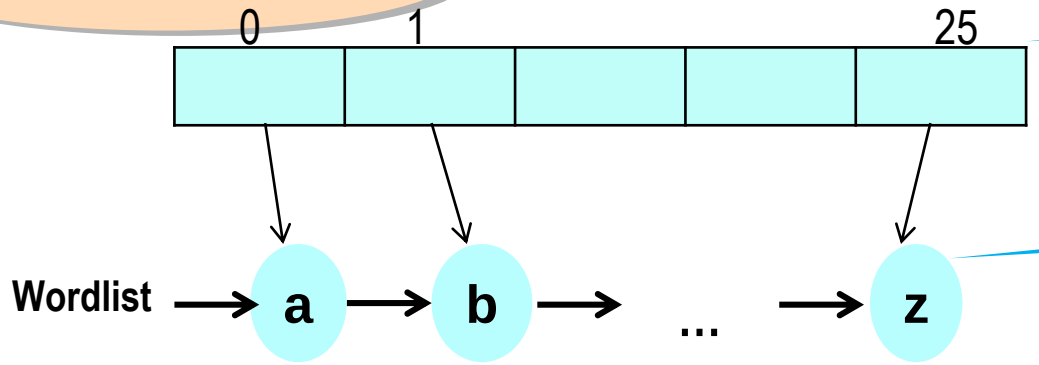

然后构造一个长度为26的指针数组，数组内容分别为指向链表中每个结点的指针
struct node *Hashtab[26];

首先构造一个仅由26个字母为单词的单词链表
struct node *Wordlist;

单词的查找不再每次由单词表的头开始，而是由查找单词的头字母开始的单词区域开始查找。在没有增加任何算法复杂度的情况下利用Hash查找方法大大提高了单词的查找效率：searchWord(word);

2.Hash函数的构建

```
int  hash(char  *word) {
    return *word - 'a' ;
}
```

3.单词的查找和插入

```
int searchWord(char *w){
    …
    h = hash(w);
    for(p=Hashtab[h]; p != NULL; q=p,p=p->link)
    …
    return insertWord(q, w);
}
```

几个字符串散列函数：https://www.cnblogs.com/dongsheng/articles/2637025.html

问题：词频统计 –查找性能分析（不同实现）

查找与存储方式	比较次数	平均比较次数	运行时间	说明
顺序查找 + 顺序表（无序）	1,604,647,193	2962.5	7.114s	不需要移动数据，但查找效率低，查找性能为O(N)
顺序查找+链表（有序）	4,151,966,169	7,665.5	97.4s	不需要移动数据，但查找效率低，查找性能为O(N)
顺序查找+链表（无序）	1,604,647,193	2962.5	26.5s	不需要移动数据，但查找效率低，查找性能为O(N)
索引结构 + 链表(有序)	208,620,575	385.1	4.517s	建立26字母开头的单词索引，有效改进了链表查找性能
折半查找 + 顺序表（有序）	6,923,725	12.8	1.103s	需要移动数据，查找性能为$O(\log_2 N)$
二叉查找树	6,768,565	12.5	0.543s	理想情况下（平衡树）查找性能为$O(\log_2 N)$,无数据移动
字典树（Trie）	3,031,958	5.6	0.49s	查找性能与单词规模无关，只与单词平均长度有关
Hash查找（30000大小）	**569,410**	**1.05**	**0.456**	**查找性能与单词规模无关，只与Hash冲突数有关**

数据说明：文本单词总数541,639，不同单词总数22,086

第 6 章

查找

本章小结

Summary

- 查找的基本概念
- 顺序表及其查找
  - 顺序文件
    - 一般顺序表、有序顺序表
    - 连续顺序表、链接顺序表
    - 有序连续顺序表
  - 连续顺序表查找
    - 顺序查找和折半查找（递归和非递归）
    - 复杂度分析（判定树）
  - 链接顺序表查找
- 索引表及其查找
  - 索引与索引表
  - 稠密索引和非稠密索引

第 6 章

查找

本章小结

Summary

- B-树与B+树
  - B-树的结构
  - B-树的查找、B-树的插入（结点分解规则）
  - B+树的结构
  - B-树与B+树的异同
- 散列（Hash）表及其查找
  - 散列
    - 散列函数及其构造方法
    - 散列冲突
  - 散列冲突处理方法
    - 开放地址法、再散列法、链地址法